Relaxation combinatoire pour l'optimisation d'ensembles de points appliquée au Problème de Thomson

Anna Malet
anna.malet@grenoble-inp.org
Ensimag 2A - Initiation à la Recherche en Laboratoire (IRL)
Gipsa-Lab, Grenoble INP
Grenoble, France

Simon Barthelmé
CNRS, Gipsa-Lab
Grenoble, France

Résumé

Le problème du placement optimal d'un ensemble de points à l'intérieur d'un domaine intervient dans de nombreuses disciplines, notamment en physique statistique (agencement de particules), en ingénierie (déploiement de capteurs) ou encore en traitement du signal (localisation de sources). Les problèmes d'optimisation qui en découlent sont trop complexes pour être résolus de manière exacte, et on se contente souvent de résoudre une version plus simple, dite « relaxée ». Dans cet article, nous étudions une nouvelle famille de relaxations combinatoires consistant à plonger l'ensemble cible de taille m dans un réservoir étendu de taille $n > m$. Cette sur-paramétrisation est exploitée par un algorithme de descente de gradient stochastique (SGD) piloté par des heuristiques de sélection de sous-ensembles. Cette approche permet de naviguer dynamiquement entre l'exploration globale de l'espace et l'exploitation locale, tout en admettant la relaxation convexe standard comme limite théorique, offrant ainsi de solides perspectives d'analyse. Nous appliquons ce cadre au problème de Thomson (minimisation de l'énergie électrostatique de m particules sur une sphère), un archétype de paysage énergétique rugueux et hautement fragmenté par ses minima locaux. Nos résultats démontrent que notre approche réduit empiriquement les effets de piégeage dans certains minima locaux. Elle surpasse systématiquement les solveurs de descente locale et rivalise en précision avec les méthodes de l'état de l'art, telles que le Parallel Tempering.

Keywords

Optimisation Non-Convexe, Problème de Thomson, Relaxation Combinatoire, Descente de Gradient Stochastique, Belief Propagation.

1 Introduction

1.1 Problématique et applications

Un très grand nombre de problèmes en mathématiques appliquées, en statistiques et en informatique nécessitent l'optimisation d'ensembles de points dans l'espace. Dans ce cadre général, il s'agit de placer de manière optimale m atomes $x_1, \dots, x_m$ dans un domaine spatial sous contraintes $\Omega \subset \mathbb{R}^d$. L'objectif est de minimiser une fonction de coût $H(X)$ définie par des interactions de paires :

$$H(X) = \sum_{i<j} h(x_i, x_j) \tag{1}$$

où $h(x, y)$ est souvent une fonction décroissante de la distance, par exemple un potentiel de Riesz $h(x, y) = \|x - y\|^{-p}$. Ces problèmes d'optimisation apparaissent dans des disciplines très variées : en ingénierie pour le placement optimal de réseaux de capteurs [9], en statistiques pour les plans d'expériences, en traitement de l'imagerie pour la localisation de sources et la déconvolution, ou encore en physique statistique et dynamique moléculaire pour déterminer l'état fondamental d'un système de particules.

Le cas d'étude principal de ce rapport est le problème de Thomson, un cas particulier célèbre et particulièrement complexe de cette classe de problèmes, où Ω est la sphère unité $\mathbb{S}^2$ et $h(x_i, x_j) = \|x_i - x_j\|^{-1}$. Formulé historiquement en 1904 dans le cadre du modèle atomique de Thomson [10], l'objectif est de trouver la configuration spatiale d'équilibre minimisant l'énergie de répulsion électrostatique d'un système d'électrons confinés à la surface d'une sphère unité.

L'enjeu mathématique central commun à toutes ces applications réside dans l'extrême difficulté de l'optimisation globale. La recherche d'une approximation en temps polynomial pour le problème de Thomson fait partie des problèmes mathématiques de Smale pour le XXIe siècle [1] et reste non résolue, le problème étant classé NP-difficile. La contrainte géométrique d'appartenance à la variété (comme la sphère) rend le domaine de recherche non-convexe. Plus critique encore, le nombre de minima locaux (états métastables) croît de manière exponentielle avec le nombre de points m. Le paysage énergétique s'apparente alors à une surface extrêmement rugueuse remplie de barrières de potentiel, empêchant la construction d'algorithmes d'approximation polynomiale garantissant l'atteinte d'une solution globale.

1.2 État de l'art : typologie et classes de solutions

La complexité du problème, qui rend toute résolution exacte directe inenvisageable, a conduit la littérature à développer différentes familles d'approches :

1.2.1 *Approches numériques directes : de l'optimisation locale aux méta-heuristiques.*

Ce premier paradigme conserve la formulation native du problème : optimiser directement les coordonnées des m particules sur le domaine continu (pour Thomson, la sphère).

L'optimisation locale. L'approche la plus immédiate consiste à exploiter l'information locale (gradients, courbures) pour guider les points vers un état de plus basse énergie. Entrent dans cette catégorie la Descente de Gradient Projeté (PGD), ainsi que des méthodes du second ordre adaptées aux variétés comme le Manifold L-BFGS [11]. Néanmoins, ces approches sont fondamentalement locales : elles s'enlisent inévitablement dans le bassin d'attraction le plus proche de leur initialisation aléatoire.

L'exploration stochastique et les méthodes de population. Pour s'extraire de ces minima locaux, la plupart des stratégies s'appuient sur des mécanismes de perturbation stochastique, via le lancement des algorithmes de recherche locale à de multiples reprises avec des initialisations différentes. En chimie computationnelle, le Basin-Hopping [5] est populaire : il alterne des phases de perturbation globale et des phases de relaxation locale (L-BFGS). Une autre famille regroupe les méthodes de Tempering, notamment le Parallel Tempering et sa variante moderne non-réversible (NRPT) [4], qui font évoluer plusieurs chaînes de Markov à des températures différentes pour franchir les barrières de potentiel. Enfin, au lieu de suivre une seule configuration, de nombreux algorithmes maintiennent une population de candidats. C'est le cas des algorithmes PT et NRPT décrits précédemment, mais aussi des méthodes de Monte Carlo Séquentiel (SMC), ou encore des méta-heuristiques classiques telles que les Algorithmes Génétiques (Genetic Programming). Bien que très variées, ces méthodes sont souvent très coûteuses en évaluations d'énergie et manquent parfois de garanties théoriques.

1.2.2 L'approche par discrétisation spatiale : la contrainte de la grille fixe. Une deuxième stratégie modifie radicalement la géométrie du problème. Au lieu de chercher des coordonnées réelles continues, on discrétise l'espace en une grille fixe comprenant un très grand nombre N de positions candidates ($N \gg m$). Cette approche, courante en théorie des plans d'expériences [14], transforme le problème en une recherche combinatoire binaire (variables dans $\{0, 1\}$) d'affectation d'atomes sur les nœuds de la grille. Cependant, le problème étant toujours NP-difficile en général sous cette forme, il faut ensuite utiliser une relaxation linéaire classique (passer de $\{0, 1\}$ à $[0, 1]$) pour rendre le problème convexe avant d'arrondir la solution, et pour obtenir une précision géométrique acceptable, la grille doit être gigantesque. L'explosion combinatoire est alors simplement déplacée de la topologie continue vers la dimensionnalité du problème discret.

1.2.3 La relaxation convexe continue. La relaxation convexe continue aborde le problème sous l'angle de la théorie de la mesure. Au lieu d'optimiser les positions discrètes des m points, la configuration est modélisée comme une mesure de probabilité discrète μ. Le domaine d'optimisation est relaxé à l'ensemble des mesures positives continues. Cette approche (qui englobe les méthodes de type Beurling-Lasso ou BLASSO [6, 7]) présente un avantage théorique immense : elle rend le problème d'optimisation globalement convexe. Elle permet de solides analyses mathématiques et offre de véritables garanties de reconstruction. Cependant, manipulées en dimension infinie, ces relaxations sont en réalité intraitables directement. Elles nécessitent des algorithmes de discrétisation adaptative très complexes à implémenter.

1.2.4 Positionnement du travail : la relaxation combinatoire sur réservoir étendu. Notre approche vise à construire un pont entre les méthodes numériques et la relaxation. Plutôt que de manipuler une mesure continue abstraite, nous opérons une relaxation combinatoire via un réservoir *fini et mobile* de n points ($m < n < \infty$). La fonction d'interaction native $H(X)$ est remplacée par une fonction coût relâchée $G_n(Y)$, définie comme l'espérance de l'énergie sur les sous-ensembles de taille m extraits de Y. Lorsque $n \to \infty$, cette fonction admet la relaxation convexe continue comme limite. À l'échelle finie, elle nous permet entre autres d'utiliser pour son optimisation une Descente de Gradient Stochastique (SGD) rapide.

1.3 Motivations et contributions

L'état de l'art met en évidence une dichotomie importante : d'un côté, des méthodes numériques pratiques (heuristiques, MCMC) souvent lourdes, coûteuses, enclines à rester piégées dans des paysages énergétiques rugueux et avec des garanties théoriques insuffisantes [3] ; de l'autre, des relaxations convexes continues dotées de garanties théoriques fortes [6], mais très difficiles à implémenter. Il apparaît donc pertinent de concevoir une méthode d'optimisation qui s'intercale entre l'optimisation locale et la relaxation en espace de dimension infinie. La relaxation combinatoire étudiée ici répond à cet enjeu via une sur-paramétrisation stratégique (le réservoir $n > m$) pilotée dynamiquement [11].

Les contributions principales de ce rapport s'articulent ainsi :

- **Développement d'heuristiques de sélection informées :** Pour diriger la SGD stochastique, nous avons implémenté et comparé deux approches d'échantillonnage visant à approximer la distribution de Boltzmann : une méthode gloutonne séquentielle (*Boltzmann*) et une approche d'inférence globale (*Belief Propagation*) [8], régulées par un recuit simulé (température dynamique).
- **Mise en évidence de régimes structurels :** L'analyse entropique de nos résultats permet de caractériser le comportement de la descente : un *régime fluide* ($n \gg m$) qui semble favoriser grandement l'exploration et l'évitement des minima locaux profonds, et un *régime gelé* ($n \approx m$) qui permet une convergence locale fine.
- **Évaluation expérimentale comparative :** Sur la base d'un benchmark statistique ($m = 46$), nos expériences suggèrent que cette approche stochastique permet de s'affranchir des limitations classiques des solveurs de descente locale (PGD, L-BFGS, Ipopt [12]). Empiriquement, la méthode atteint des niveaux d'énergie comparables à ceux du Parallel Tempering non-réversible (NRPT) [4], avec un temps d'exécution sensiblement réduit sur nos instances de test.

2 Relaxation Combinatoire

2.1 Fonction de coût relâchée et pool de configurations

Soit un ensemble cible de m points $x_1, \dots, x_m \in \Omega^m$. Notons $X = \{x_i, i \in 1 \dots m\} \subset \Omega$ la configuration des points. Nous cherchons à minimiser

$$\underset{x_1,\dots,x_m \in \Omega^m}{argmin} \; H(x_1, \dots, x_m).$$

Au lieu de minimiser $H(X)$ directement, nous introduisons un réservoir étendu de points $Y = \{y_1, \dots, y_n\} \subset \Omega$, avec $n > m$. La fonction de coût relaxée $G_n(Y)$ est l'espérance de l'énergie sur des sous-ensembles aléatoires de taille m extraits de Y selon une distribution q :

$$G_n(Y) = \mathbb{E}_{\mathcal{X} \sim q(\cdot|Y)} \left[H(\mathcal{X}) \right] = \sum_{\mathcal{X} \subset Y, |\mathcal{X}|=m} q(\mathcal{X}) H(\mathcal{X}) \qquad (2)$$

Cette formulation permet d'interpoler entre les régimes :

- Si $n = m$, $G_m(Y) = H(Y)$: aucune relaxation.

— Si $n \to \infty$, $G_n(Y)$ converge vers la relaxation convexe continue sur l'espace des mesures.

Ce plongement confère une plasticité algorithmique : si un atome y_k est mal placé, la distribution q peut l'exclure temporairement, permettant au reste de s'optimiser.

2.2 Le gradient stochastique

La descente de gradient stochastique (SGD) minimise une fonction $f(x)$ via des itérations de la forme :

$$x_{t+1} = x_t - \gamma_t Z_t \tag{3}$$

où Z_t est un estimateur sans biais du gradient, c'est-à-dire $\mathbb{E}(Z_t) = \nabla f(x_t)$, et γ_t est un paramètre de taille de pas. La méthode SGD est fondamentale pour l'apprentissage automatique moderne, étant utilisée presque exclusivement pour l'entraînement de modèles sur de grands ensembles de données [13].

Ici, nous nous intéressons à l'optimisation de la fonction de coût relaxée $G_n(Y)$. En considérant Y comme un vecteur échangeable d'atomes $y_1, \ldots, y_n$ de sorte qu'il soit logique de calculer un gradient par rapport à Y, on peut vérifier que la procédure suivante est en fait une instance de SGD :

(1) Sélectionner un sous-ensemble aléatoire $\mathcal{X}$ de Y selon la distribution $q(\mathcal{X})$. De manière équivalente, échantillonner des indices $j_1, \ldots, j_m$ tels que $x_i = y_{j_i}$.

(2) Calculer le gradient $\nabla H(\mathcal{X})$ par rapport aux atomes échantillonnés.

(3) Déplacer les atomes selon le gradient : $y_{j_i} \leftarrow x_i - \gamma(\nabla H(\mathcal{X}))_i$.

Algorithm 1 Descente de Gradient Stochastique pour la Relaxation Combinatoire Générale

Require: Taille du réservoir n, taille du sous-ensemble cible m, pas d'apprentissage γ, nombre total d'itérations T, distribution de sélection q, domaine sous contraintes Ω.

Ensure: Réservoir d'atomes optimisé $Y^{(T)} = \{y_1^{(T)}, \ldots, y_n^{(T)}\} \subset \Omega$.

Initialiser le réservoir $Y^{(0)} = \{y_1^{(0)}, \ldots, y_n^{(0)}\}$ aléatoirement dans le domaine Ω.
for $t = 0$ **to** $T - 1$ **do**
  Sélectionner un sous-ensemble aléatoire d'indices $S \subset \{1, \ldots, n\}$ de taille m selon la distribution $q(\cdot|Y^{(t)})$.
  Définir la configuration active correspondante : $\mathcal{X} = \{y_i^{(t)}\}_{i \in S}$.
  Calculer le gradient de l'énergie d'interaction $\nabla H(\mathcal{X})$ par rapport aux atomes actifs.
  {Mise à jour des atomes sélectionnés}
  for all $i \in S$ **do**
    $g_i \leftarrow \nabla_{y_i} H(\mathcal{X})$
    $y_i^{(t+1)} \leftarrow \text{Projection}_\Omega\left(y_i^{(t)} - \gamma g_i\right)$
  end for
  for all $i \notin S$ **do**
    $y_i^{(t+1)} \leftarrow y_i^{(t)}$
  end for
end for
return $Y^{(T)}$

Cette procédure est très similaire à l'exécution d'une descente de gradient standard sur un ensemble fixe $\mathcal{X}$, mais ici, un sous-ensemble aléatoire est construit à partir du réservoir à chaque itération.

Ce que nous pouvons espérer de cette procédure est de construire un réservoir qui contient de nombreux bons candidats pour des minimisateurs approchés de $\mathcal{X}$, le mécanisme stochastique permettant d'échapper aux minima locaux et le choix du sous-ensemble agissant comme une perturbation de la structure.

Notre problème impose également une contrainte stricte d'appartenance à l'espace cible, pour le problème de Thomson la variété sphérique $\mathbb{S}^2$. Pour respecter la géométrie du problème, le gradient est projeté à chaque itération sur l'espace tangent à la sphère en chaque point x_i :

$$\text{grad}\, H(x_i) = \nabla H(x_i) - \langle \nabla H(x_i), x_i \rangle x_i \tag{4}$$

Cette opération de projection, suivie d'une normalisation, permet au réservoir de particules d'évoluer de manière fluide sur la variété.

2.3 Heuristiques de sélection de sous-ensembles

L'efficacité de notre méthode relaxation combinatoire dépend de la capacité de la distribution d'échantillonnage $q(\mathcal{X})$ à sélectionner des sous-ensembles de bonne qualité. Idéalement, nous souhaiterions définir la distribution de sélection q telle que :

$$q(\mathcal{X}) \propto \exp(-\beta H(\mathcal{X})) \tag{5}$$

où β est un paramètre inverse de la température.

Cependant, cette approche exacte est beaucoup trop coûteuse, car elle nécessite d'évaluer le coût énergétique de chaque sous-ensemble possible, rendant l'échantillonnage direct selon q impossible dès que le réservoir grandit. Pour contourner ce problème, une alternative consiste à approcher cette distribution en incluant chaque atome y_i avec une probabilité proportionnelle à sa probabilité marginale d'inclusion sous la loi $\exp(-\beta H(\mathcal{X}))$. Bien que le calcul exact de ces marginales reste intraitable, il peut être approximé par des algorithmes efficaces comme la Belief Propagation (BP), ou par des heuristiques séquentielles plus simples. Nous mettons en œuvre et comparons ici deux stratégies d'approximation distinctes : l'une locale et séquentielle (Boltzmann glouton), et l'autre globale et variationnelle (Belief Propagation).

2.3.1 L'Échantillonneur de Boltzmann glouton (Élimination séquentielle). Cette première heuristique a été choisie pour sa simplicité d'implémentation et son faible coût computationnel initial. Elle remplace la sélection globale par un processus d'élimination séquentielle. Plutôt que de construire un sous-ensemble de taille m en partant de zéro, l'algorithme initialise la configuration active avec l'intégralité du réservoir $A^{(0)} = \{1, \ldots, n\}$ et élimine un à un les $n - m$ atomes les plus instables.

À chaque étape d'élagage k (allant de 1 à $n - m$), le système se trouve dans un état intermédiaire défini par l'ensemble des indices restants $A^{(k-1)}$. La contribution énergétique individuelle de chaque particule $i \in A^{(k-1)}$ est calculée par :

$$E_i^{(k)} = \sum_{j \in A^{(k-1)}, j \neq i} h(y_i, y_j) = \sum_{j \in A^{(k-1)}, j \neq i} \frac{1}{\|y_i - y_j\|_2} \tag{6}$$

La probabilité de rejeter la particule i_k à l'étape k est alors modélisée par :

$$P(i_k \text{ éliminée} \mid A^{(k-1)}) = \frac{\exp\left(\beta E_{i_k}^{(k)}\right)}{\sum_{l \in A^{(k-1)}} \exp\left(\beta E_l^{(k)}\right)} \tag{7}$$

Le signe positif devant l'énergie garantit que les particules subissant la plus forte répulsion mutuelle ont la probabilité maximale d'être exclues du pool actif. Le paramètre β contrôle le compromis exploration/exploitation.

Expression de la distribution $q(\mathcal{X})$ associée. Soit $\mathcal{X}$ un sous-ensemble final de taille m et soit $S^c = \{i_1, i_2, \ldots, i_{n-m}\}$ l'ensemble des indices éliminés pour aboutir à $\mathcal{X}$. Comme l'ordre d'élimination des points de S^c influe sur les trajectoires intermédiaires, la probabilité finale d'obtenir la configuration $\mathcal{X}$ est obtenue en sommant sur l'ensemble des $(n-m)!$ permutations possibles π de l'ordre d'exclusion :

$$q_{\text{Boltz}}(\mathcal{X}) = \sum_{\pi \in \text{Perm}(S^c)} \prod_{k=1}^{n-m} P(i_k \text{ éliminée} \mid A_\pi^{(k-1)}) \tag{8}$$

où $A_\pi^{(k-1)} = \{1, \ldots, n\} \setminus \{i_1, \ldots, i_{k-1}\}$ sous la permutation π.

Limites de la méthode. Bien qu'efficace pour guider grossièrement le SGD, cette approche reste une approximation gloutonne. Une particule éliminée prématurément à l'étape k ne peut jamais être réintégrée, même si les déplacements géométriques ultérieurs des autres atomes auraient rendu sa position optimale à la fin du processus. De plus, l'expression de $q_{\text{Boltz}}(\mathcal{X})$ met en évidence une dépendance structurelle forte à l'égard de l'historique d'élimination, ce qui introduit une variance élevée dans les estimations du gradient stochastique.

2.3.2 L'Échantillonneur par Belief Propagation (BP). Pour obtenir une estimation globale des probabilités d'inclusion des atomes et pallier les limites de l'approche gloutonne, nous modélisons le choix du sous-ensemble optimal comme un problème d'inférence probabiliste. Le graphe d'interaction est complet, chaque nœud i étant connecté à tous les autres par une répulsion $H_{ij} = \|y_i - y_j\|_2^{-1}$. L'algorithme Belief Propagation dans sa variante Sum-Product [8] est utilisé pour calculer les messages $U_{i \to j}$ (exprimés en log-odds) échangés entre les atomes.

Pour forcer la convergence sur ce graphe complet où l'abondance de boucles viole l'hypothèse de cavité de BP, deux mécanismes de régulation sont appliqués à chaque itération :

(1) Potentiel chimique dynamique (μ) : Un champ global μ est ajusté dynamiquement pour cibler la taille du sous-ensemble. Les probabilités marginales $p_i = \frac{1}{1+\exp(-(\mu + \sum U_{\text{in}}))}$ sont calculées, et μ est mis à jour (via $\mu \leftarrow \mu + 0.2(m - \sum p_i)$) pour forcer la somme des probabilités d'inclusion à valoir exactement m.

(2) Amortissement et Sum-Product : Le nouveau message est calculé via la formule exacte du Sum-Product pour l'interaction binaire : $U_{\text{new}} = \log\left(\frac{\exp(-\beta H_{ij})\exp(U_{\text{cav}})+1}{\exp(U_{\text{cav}})+1}\right)$. Pour éviter les résonances et les dépassements de capacité, le champ cavité U_{cav} est borné à ± 50.0, puis une mise à jour amortie est appliquée : $U \leftarrow \lambda U + (1-\lambda)U_{\text{new}}$ (avec $\lambda = 0.8$).

Une fois le point fixe des messages atteint, les croyances finales de chaque particule (en log-odds) sont établies : $b_i = \mu + \sum_{k \neq i} U_{k \to i}$.

Décimation séquentielle avec soulagement. Contrairement à un simple tirage indépendant, l'échantillonnage de la configuration finale $\mathcal{X}$ s'effectue par une décimation séquentielle. L'algorithme part du réservoir complet et élimine itérativement $n - m$ atomes. À chaque étape :

(1) Une probabilité d'élimination est assignée aux atomes actifs via un Softmax (de température τ) sur l'inverse de leurs croyances : $w_i \propto \exp(-(b_i - \min b)/\tau)$, forçant les atomes ayant les plus faibles croyances à être éliminés en priorité.

(2) L'atome sélectionné est retiré du pool.

(3) Soulagement local : Plutôt que de relancer le coûteux algorithme BP, les croyances des atomes restants sont mises à jour par une heuristique de soulagement. La répulsion exercée par l'atome éliminé est soustraite des croyances des atomes voisins ($b_{\text{voisin}} \leftarrow b_{\text{voisin}} + \beta H_{\text{supprimé, voisin}}$).

Expression formelle de la distribution $q(\mathcal{X})$ produite. Soit $\mathcal{X}$ un sous-ensemble final de taille m, et $S^c = \{i_1, i_2, \ldots, i_{n-m}\}$ la séquence des atomes éliminés. La probabilité $q_{\text{BP}}(\mathcal{X})$ d'obtenir cet ensemble est la somme, sur toutes les permutations possibles π de S^c, des probabilités de cette chaîne de décimation :

$$q_{\text{BP}}(\mathcal{X}) = \sum_{\pi \in \text{Perm}(S^c)} \prod_{k=1}^{n-m} \frac{\exp\left(-\frac{b_{i_k}^{(k-1)}}{\tau}\right)}{\sum_{j \in A^{(k-1)}} \exp\left(-\frac{b_j^{(k-1)}}{\tau}\right)} \tag{9}$$

où $A^{(k-1)}$ est l'ensemble actif à l'étape k, et $b^{(k-1)}$ sont les croyances tenant compte des soulagements successifs.

Limites de la méthode BP. Bien que cette méthode génère des configurations initiales de bien meilleure qualité que l'approche purement gloutonne, elle est grevée par la complexité en $O(n^2)$ du calcul des messages sur le graphe complet à chaque itération du Sum-Product. De plus, dans le régime où $n \approx m$, les contraintes fortes du système dominent le processus variationnel : la décimation se fige sur un sous-ensemble quasi-déterministe, réduisant l'entropie d'exploration à une valeur proche de zéro.

3 Résultats Numériques

3.1 Analyse du paysage énergétique du problème

L'étude des bassins d'attraction pour un système de taille modérée ($n = 38$) met en évidence la fragmentation précoce du paysage énergétique du problème de Thomson [2, 3]. Les statistiques de convergence issues de multiples initialisations aléatoires révèlent une topographie dominée par l'émergence de deux macro-bassins métastables majeurs, qui se partagent presque équitablement l'espace de recherche avec des fréquences relatives de l'ordre de 50% chacun. Fait remarquable, le bassin associé au minimum global n'a pas le plus grand volume de capture : l'algorithme de descente locale converge préférentiellement vers l'état sous-optimal [3].

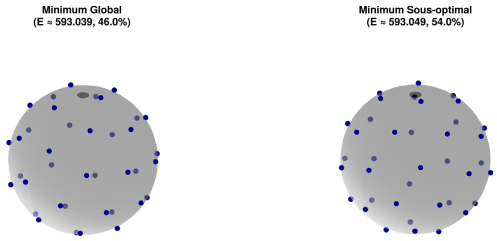


Figure 1 : Représentation des deux configurations géométriques dominantes pour $n = 38$ (à gauche : minimum global, à droite : minimum sous-optimal).

La Figure 1 illustre la structure tridimensionnelle de ces deux configurations concurrentes. Cette proximité géométrique et énergétique implique qu'une optimisation locale classique possède près d'une chance sur deux de s'enclaver définitivement dans un puits métastable [3]. L'existence de telles barrières de potentiel rend les méthodes de descente directe inopérantes sans stratégie globale d'évasion [4, 5]. Ce caractère trompeur, présent dès les petites instances, légitime pleinement l'introduction de la relaxation combinatoire pour s'affranchir de ces impasses topologiques.

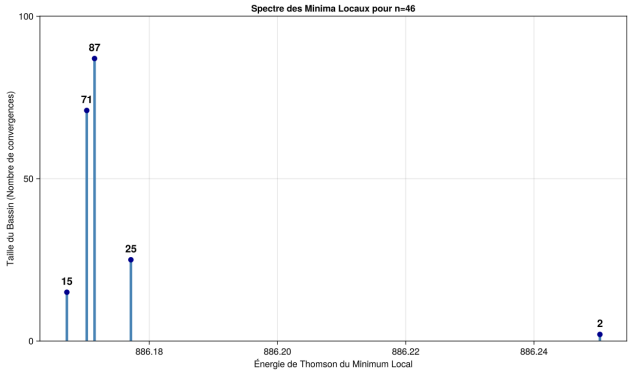


Figure 2 : Spectre énergétique et tailles des bassins d'attraction pour $n = 46$ (échelle logarithmique), découverts via 200 initialisations du solveur Ipopt.

L'analyse du paysage énergétique pour $m = 46$ dans la Figure 2 illustre un premier niveau de complexité. L'axe des abscisses représentant directement l'énergie du minimum, on constate que la surface de l'espace de recherche se fracture en une multitude de bassins d'attraction concurrents. La difficulté majeure saute immédiatement aux yeux grâce à l'échelle logarithmique : le bassin d'attraction menant au minimum global (le point le plus à gauche) possède une taille de capture extrêmement faible. À l'inverse, des minima locaux nettement sous-optimaux, situés à des énergies plus élevées, dominent massivement la topographie et agissent comme des points d'attraction pour les descentes de gradient.

Au-delà de $n = 46$, lorsque l'on tend vers des systèmes plus grands comme $n = 100$, la complexité combinatoire s'accroît de manière exponentielle. Le paysage énergétique subit alors une fragmentation extrême, caractérisée par une prolifération de minima locaux isolés dont les bassins d'attraction deviennent quasi-unitaires. Statistiquement, la probabilité qu'une méthode d'optimisation locale initiée au hasard converge directement vers l'état fondamental tend ainsi vers zéro. Cette prolifération ultra-rapide des structures de défauts à la surface de la sphère a été largement documentée [2]. L'identification de l'état fondamental parmi cette multitude d'attracteurs concurrents constitue l'un des verrous majeurs de la physique computationnelle contemporaine [16].

3.2 Influence du réservoir et convergence

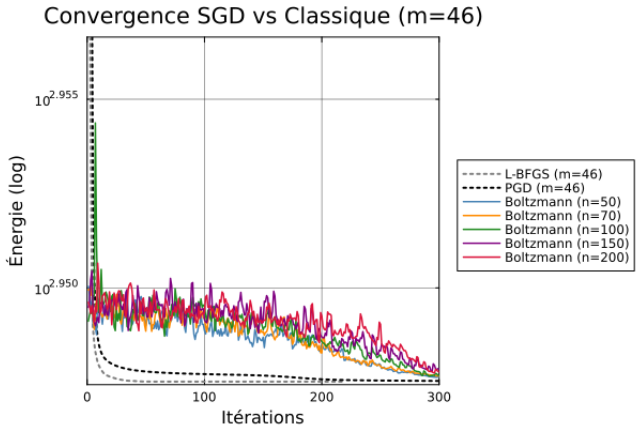


Figure 3 : Convergence des algorithmes classiques et de notre méthode

L'évolution de l'énergie au fil des itérations présentée dans la Figure 3 met en évidence des dynamiques radicalement différentes entre les approches classiques et notre méthode stochastique. Dès les premières itérations, les solveurs classiques (PGD et L-BFGS) chutent brutalement de manière monotone, mais se figent définitivement sur un plateau énergétique localement minimal mais globalement sous-optimal.

Au contraire, les trajectoires associées à notre méthode de descente de gradient stochastique se situent visuellement au-dessus des baselines déterministes durant la majeure partie de la descente. Cette position plus élevée dans le graphique ne doit pas être interprétée comme une mauvaise convergence, mais découle directement du mode d'évaluation : l'énergie tracée à chaque itération correspond à l'énergie instantanée $H(X_t)$ du sous-ensemble actif sélectionné pour cette itération spécifique, et non à l'énergie du meilleur sous-ensemble X extrait du pool. Ce niveau d'énergie plus élevé et soumis à des fluctuations reflète la phase d'exploration active du réservoir, le bruit introduit par l'échantillonneur (Boltzmann ou BP) permettant précisément au nuage de points global d'éviter de se faire capturer par les premiers minima locaux rencontrés.

L'analyse de la Figure 3 illustre également l'impact crucial de la taille du réservoir n sur la qualité de cette restructuration géométrique. La courbe pour $n = 50$ montre qu'avec trop peu de points excédentaires, le système manque de plasticité ; le manque de variables latentes empêche un brassage suffisant, ce qui conduit à une

stagnation précoce. L'augmentation de la taille du réservoir ($n = 70$ et $n = 100$) débloque la situation en offrant la liberté géométrique nécessaire pour faciliter l'exploration du paysage énergétique. Bien que l'énergie instantanée affichée en cours de route reste élevée pour les raisons explicitées ci-dessus, c'est cette reconfiguration adaptative du réservoir complet qui permet, lors de la décimation finale suivie d'un raffinement local (*quench* par L-BFGS), de découvrir les configurations de plus basse énergie reportées dans le Tableau 1.

Enfin, un sur-dimensionnement excessif ($n = 150$ ou $n = 200$) s'avère contre-productif : il s'accompagne d'un bruit stochastique disproportionné, matérialisé par les fortes oscillations des courbes rouge et violette, ce qui ralentit la vitesse de convergence sans apporter de bénéfice sur la qualité de l'état fondamental atteint. Un juste milieu (autour de $n = 70$ à $n = 100$) représente ainsi le compromis optimal entre la capacité d'évasion topologique et la maîtrise de la variance du gradient.

3.3 Dynamique de sélection et entropie : étude comparative

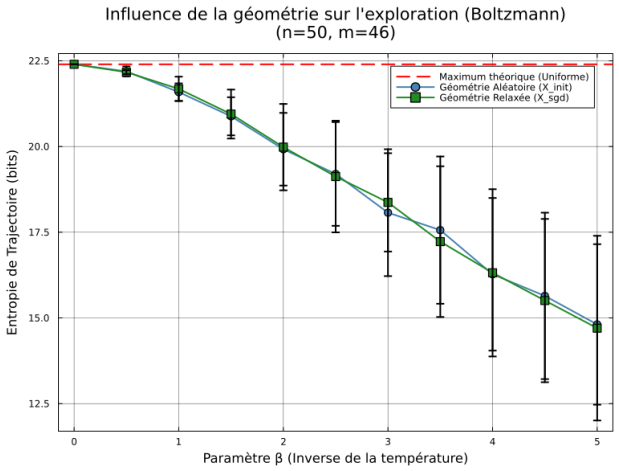


Figure 4 : Évolution de l'entropie de sélection des sous-ensembles avec β.

Le graphique d'entropie de la Figure 4 quantifie précisément le compromis entre l'exploration de l'espace combinatoire et l'exploitation des caractéristiques géométriques selon la température inverse β. En régime statique, à $\beta = 0$, l'algorithme procède à une sélection totalement aléatoire, ce qui se traduit par une entropie maximale proche de la limite théorique uniforme. Cette phase correspond à une exploration aveugle, incapable de consolider la moindre sous-structure cristalline. À mesure que β augmente, l'entropie de la trajectoire d'élimination décroît de manière quasi-linéaire, illustrant un comportement de plus en plus déterministe. L'échantillonneur de Boltzmann devient alors « glouton » : il cible et élimine préférentiellement les points subissant les plus fortes contraintes électrostatiques. Cette chute d'entropie révèle que l'algorithme a identifié des points faibles redondants à sacrifier pour stabiliser le reste de la sphère. Le léger décalage entre les géométries initiales aléatoires et celles relaxées par SGD souligne d'ailleurs que la descente de gradient oriente activement ces choix d'élimination structurelle.

Planification dynamique de la température inverse (Recuit). Pour tirer le meilleur parti de ce spectre entropique, notre implémentation ne s'appuie pas sur un paramètre β figé. Nous avons introduit une planification dynamique (analogue à un schéma de recuit simulé) où la température inverse évolue linéairement au fil des itérations t :

$$\beta_t = 0.1 + \left(\frac{t}{T_{\max}}\right) \times 10.0 \tag{10}$$

où $T_{\max}$ est le nombre total d'itérations.

Cette stratégie permet de découpler temporellement les phases d'optimisation :

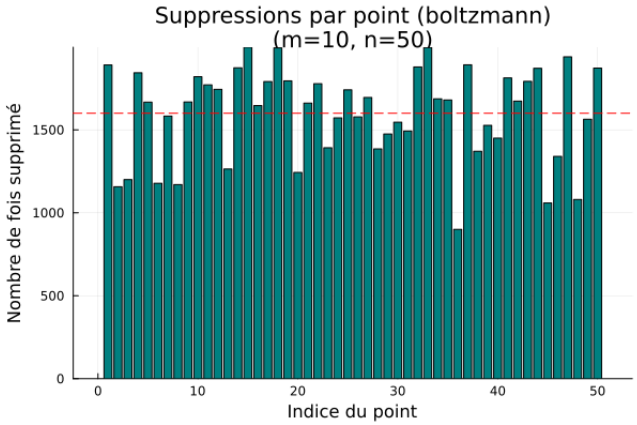
- **Phase d'exploration (Faible β_t) :** En début de processus ($\beta_0 = 0.1$), le système se trouve dans un régime à « haute température ». La sélection quasi-uniforme maintient une entropie élevée qui empêche le réservoir de points de se figer prématurément dans le premier minimum local rencontré. Cette forte plasticité permet d'explorer globalement la sphère et de briser les mauvaises configurations initiales.
- **Phase d'exploitation (Fort β_t) :** À mesure que t augmente, le système « refroidit ». L'algorithme bascule progressivement vers un régime glouton ($\beta \approx 10.1$). L'entropie chute, forçant l'algorithme à exploiter les vallées énergétiques découvertes précédemment pour raffiner localement la configuration.

Cette approche montre empiriquement une amélioration significative par rapport à l'utilisation d'un β statique en éliminant le dilemme du paramétrage. Le recuit dynamique permet une exploration efficace lors des premières itérations et réduit les effets de piégeage précoce, tout en garantissant une convergence stable et déterministe en fin de course.

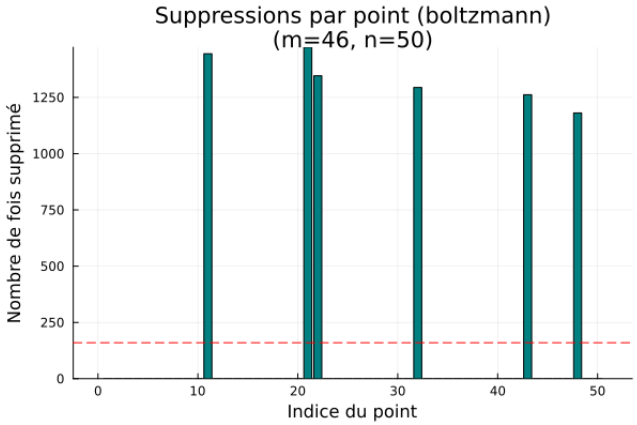
Toutefois, l'entropie dépend avant tout d'un second facteur critique : la contrainte dictée par le ratio entre la taille du réservoir n et la taille du sous-ensemble cible m. En effet, la liberté de navigation offerte par le recuit est directement bridée ou amplifiée par le nombre de sélections possibles. L'analyse empirique des fréquences de suppression et des co-occurrences de paires révèle alors l'émergence de deux régimes structurels distincts.

3.3.1 Régime de forte sur-paramétrisation ($n \gg m$). Ce premier régime, illustré par les configurations ($m = 10, n = 50$) ou ($m = 46, n = 100$), se caractérise par une grande fluidité structurelle. Lorsque le réservoir est vaste, le système dispose d'une plasticité maximale. Même pour des valeurs intermédiaires de température inverse (par exemple $\beta = 0.5$), les suppressions par point avec l'échantillonneur de Boltzmann oscillent raisonnablement autour de la moyenne théorique uniforme.

Comme le met en évidence la Figure 5a, aucun atome n'apparaît comme strictement indispensable ni systématiquement rejeté, ce qui traduit le maintien d'une distribution à forte entropie. La matrice de co-occurrence associée (Figure 6) confirme cette propriété : sa forte densité (dominée par des teintes jaunes et vertes) prouve un excellent brassage macroscopique, indiquant que presque toutes les paires possibles finissent par être exclues conjointement au cours de la descente.



(a) Forte sur-paramétrisation ($m = 10, n = 50, \beta = 0.5$).



(b) Régime $n \approx m$ ($m = 46, n = 50$).

Figure 5 : Analyse comparative des fréquences de suppression par point avec l'échantillonneur de Boltzmann. En (a), la distribution fluctue autour de la moyenne uniforme (ligne rouge). En (b), les rejets se concentrent exclusivement sur un groupe réduit d'une dizaine de points sous l'effet du gel structurel.

À l'inverse, l'échantillonneur par Belief Propagation (BP) manifeste dans ce même régime une distribution spatiale presque parfaitement uniforme, à l'exception de quelques pics isolés. BP calculant des approximations variationnelles des probabilités marginales exactes, un point immergé dans un amas local de sur-densité verra sa croyance s'effondrer et sa probabilité de suppression tendre vers 1, tandis que le reste du nuage continue de s'échantillonner avec une homogénéité globale.

3.3.2 Régime $n \approx m$. Lorsque la marge de manœuvre s'amenuise et que la taille du réservoir approche la cardinalité cible (par exemple $m = 46, n = 50$), la pression combinatoire étouffe le comportement stochastique. L'espace des configurations admissibles se restreint drastiquement, provoquant un phénomène de gel structurel où la distribution q s'effondre vers une somme de fonctions de Dirac.

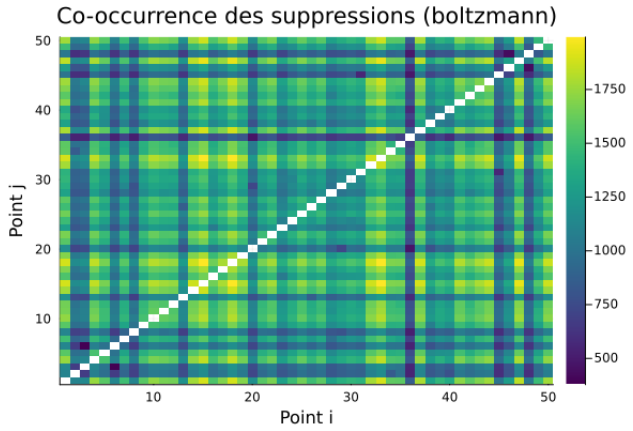


Figure 6 : Matrice de co-occurrence des suppressions avec Boltzmann ($m = 10, n = 50$). La densité de la matrice révèle un excellent brassage des particules.

Comme l'illustre la Figure 5b, l'immense majorité des atomes du pool présente un taux de rejet nul, devenant strictement intouchable en raison de leur contribution majeure à la stabilité globale du réseau. La totalité des suppressions se concentre alors exclusivement sur un noyau périphérique d'une dizaine de points instables. La matrice de co-occurrence correspondante devient presque entièrement noire, matérialisant le fait que l'algorithme conserve la structure relativement stable du motif cristallin central pour éviter des pénalités énergétiques rédhibitoires.

Ce basculement est poussé à son paroxysme avec la Belief Propagation : le système converge rapidement vers une configuration stable en excluant systématiquement les quatre mêmes particules, tandis que les 46 autres forment une configuration fortement contrainte. La co-occurrence de BP fait alors apparaître des blocs géométriques discrets hautement contrastés, reflets de micro-échanges coordonnés (permutations locales) entre les rares éléments exclus.

3.3.3 La limite de l'échantillonneur uniforme. À titre de comparaison, l'échantillonneur uniforme produit une distribution parfaitement plate où chaque point possède la même probabilité d'être rejeté, indépendamment de sa position ou de l'énergie locale. Bien que maximisant l'entropie de manière constante, cette approche détruit en permanence les bonnes structures que la descente de gradient tente de consolider. Se comportant comme un bruit thermique statique et non informé, elle empêche toute relaxation efficace et condamne le système à stagner à des niveaux d'énergie élevés.

3.4 Synthèse de la Dynamique Temporelle (Référence Annexe)

L'étude de la dynamique spatiale des points au fil des itérations détaillée en Annexe confirme les résultats statistiques obtenus avec l'entropie marginale et la probabilité de co-occurence. Comme résumé dans l'analyse des trajectoires, nous observons une transition de phase nette entre deux régimes :

— **Le régime fluide ($n \gg m$)** : les particules naviguent continuellement, sautant entre les minima, ce qui valide la forte entropie observée.
— **Le régime gelé ($n \approx m$)** : la structure se fige dans un puits de potentiel, limitant l'exploration à des micro-échanges, ce qui explique l'effondrement de l'entropie.

3.5 Benchmark Statistique Global (m=46)

Afin de lisser la variance inhérente aux algorithmes stochastiques et aux initialisations aléatoires, le tableau 1 présente les résultats moyennés sur plusieurs lancements indépendants. Les évaluations temporelles ont été réalisées sur un processeur standard sans parallélisation massive.

Table 1 : Benchmark Statistique sur 40 lancements indépendants (m=46)

Méthode	Énergie Moyenne (± Std)	Temps Moyen (s)
PGD	886.172307 (±0.003063)	0.019
Manifold L-BFGS	886.173748 (±0.012867)	0.094
Ipopt	886.173161 (±0.012795)	1.091
Parallel Tempering	886.170284 (±0.002722)	2.561
NRPT	886.168199 (±0.001499)	12.276
SGD Boltzmann (n=50)	886.170885 (±0.002327)	0.682
SGD BP (n=50)	886.170342 (±0.002754)	1.762
SGD Boltzmann (n=70)	886.175013 (±0.017678)	1.964
SGD BP (n=70)	886.172148 (±0.003048)	3.032
SGD Boltzmann (n=100)	886.171824 (±0.003330)	6.158
SGD BP (n=100)	886.171493 (±0.002822)	5.671
SGD Boltzmann (n=150)	886.171544 (±0.002983)	20.489
SGD BP (n=150)	886.171200 (±0.003051)	13.307
SGD Boltzmann (n=200)	886.174072 (±0.012747)	49.303
SGD BP (n=200)	886.171358 (±0.003134)	24.896

L'analyse statistique présentée dans le tableau 1 confirme la robustesse de la relaxation combinatoire. Contrairement aux méthodes locales (PGD, L-BFGS) qui s'enlisent dans des minima locaux variables (voir variance dans le tableau), notre approche présente une bonne stabilité. On observe que pour $n = 100$, l'algorithme atteint l'optimum global de manière quasi déterministe. Cette fiabilité permet d'atteindre expérimentalement une précision proche du NRPT.

De plus, on observe bien que prendre un n très grand par rapport à m n'a pas d'avantage significatif pour les performances. Par exemple, pour BP, passer de $n = 100$ à $n = 200$ fait exploser le temps de calcul tout en augmentant la variance, sans gain sur l'énergie finale.

4 Conclusion

4.1 Résumé

Ce travail d'initiation à la recherche a exploré l'application de la relaxation combinatoire pour la résolution du problème complexe du placement optimal de m points dans l'espace, avec la réalisation de tests sur le problème de Thomson. En substituant à la configuration rigide de m particules un réservoir sur-paramétré de n atomes (avec $n > m$), nous avons formulé le problème sous une espérance probabiliste. Cette modélisation a permis la mise en œuvre d'un algorithme de descente de gradient stochastique (SGD) dont la direction d'exploration est pilotée par des algorithmes d'échantillonnage informés (Boltzmann glouton et Belief Propagation).

4.2 Bilan

Les résultats numériques obtenus suggèrent que la relaxation combinatoire constitue un compromis très intéressant entre l'optimisation locale classique et les méthodes MCMC à population globale. L'introduction de points excédentaires dans le réservoir semble faciliter l'exploration du paysage énergétique, permettant à l'algorithme d'éviter les premiers minima locaux lors de sa phase fluide (haute entropie), pour ensuite converger avec précision lors du gel structurel induit par le refroidissement de la température de sélection.

Expérimentalement, le couplage de la SGD avec l'échantillonneur de Boltzmann s'est avéré particulièrement compétitif : il atteint expérimentalement des performances proches du NRPT, l'une des méthodes les plus performantes de l'état de l'art, tout en présentant une exécution algorithmique sensiblement plus rapide.

Toutefois, ces résultats doivent être nuancés. Bien que le problème de paramétrisation soit amoindri par le recuit dynamique, le choix du ratio optimal d'excédent de points (n/m) reste un réglage empirique essentiel à la réussite de la minimisation. De plus, l'algorithme reste parfois bloqué sur des minima locaux pour des instances particulièrement difficiles du problème (m=46, m=188), plus que pour le NRPT.

4.3 Perspectives

Plusieurs pistes de recherche s'ouvrent à la suite de cette étude.
— L'échec de l'échantillonneur uniforme souligne la nécessité d'une sélection informée par l'énergie pour garantir la convergence, et il serait intéressant de tester des algorithmes approximant de manière plus efficace et plus globale la distribution idéale.
— Une autre piste serait d'explorer des distributions de sélection basées sur les Processus Ponctuels Déterminantaux (DPP), pour assurer une diversité spatiale et énergétique maximale dans l'échantillonnage tout en bénéficiant de mécanismes d'échantillonnage exacts.
— Il pourrait également être intéressant de tester un mélange du Parallel Tempering et de cette méthode, avec des swaps entre des chaînes ayant des tailles de réservoir n différentes, pour accélérer le brassage thermique.
— Enfin, il serait aussi très intéressant d'étudier le régime stationnaire du SGD, pour connaître sa distribution stationnaire et éventuellement en tirer partie pour utiliser des résultats théoriques existants [15].

Remerciements

Je tiens à remercier tout particulièrement Simon Barthelmé, qui m'a suivie et conseillée tout au long de ce stage.

J'exprime également ma reconnaissance à mes nombreux et parfois temporaires collègues de bureau, notamment pour leurs conseils concernant la rédaction de ce rapport.

Enfin, je remercie aussi l'Ensimag pour l'opportunité d'initiation à la recherche qu'offre ce programme IRL.

Références

[1] S. Smale, *Mathematical problems for the next century*, Mathematics : frontiers and perspectives, pp. 271-294, American Mathematical Society, 2000.

[2] D. J. Wales, H. McKay, et P. W. K. Altschuler, *Structure and dynamics of spherical crystals characterized for the Thomson problem*, Physical Review E, vol. 79, 2006.

[3] P. Amore, V. Figueroa, E. Diaz, J. A. López, et T. Vincent, *Exploring the Energy Landscape of the Thomson Problem : Local Minima and Stationary States*, Journal of Statistical Physics, vol. 192, no. 10, 2025.

[4] S. Syed, A. Bouchard-Côté, G. Deligiannidis, et A. Doucet, *Non-Reversible Parallel Tempering : a scalable, highly parallel MCMC scheme*, Journal of the Royal Statistical Society Series B, 2021. arXiv preprint arXiv :1905.02939.

[5] D. J. Wales et J. P. K. Doye, *Global Optimization by Basin-Hopping and the Lowest Energy Structures of Lennard-Jones Clusters Containing up to 110 Atoms*, The Journal of Physical Chemistry A, vol. 101, no. 28, pp. 5111-5116, 1997.

[6] J.-M. Azais, Y. De Castro, et F. Gamboa, *Spike detection from inaccurate samplings*, Applied and Computational Harmonic Analysis, vol. 38, no. 2, pp. 177-195, 2015.

[7] V. Duval et G. Peyré, *Exact support recovery for sparse spikes deconvolution*, Foundations of Computational Mathematics, vol. 15, no. 5, pp. 1315-1355, 2015.

[8] M. J. Wainwright et M. I. Jordan, *Graphical models, exponential families, and variational inference*, Foundations and Trends in Machine Learning, vol. 1, no. 1-2, pp. 1-305, 2008.

[9] F. Ghayem, B. Rivet, R. C. Farias, et C. Jutten, *Robust Sensor Placement for Signal Extraction*, IEEE Transactions on Signal Processing, vol. 69, pp. 4513-4528, 2021.

[10] J. J. Thomson, *On the Structure of the Atom : an Investigation of the Stability and Periods of Oscillation of a number of Corpuscles arranged at equal intervals around the Circumference of a Circle ; with Application of the Results to the Theory of Atomic Structure*, Philosophical Magazine, vol. 7, no. 39, pp. 237-265, 1904.

[11] P.-A. Absil, R. Mahony, et R. Sepulchre, *Optimization Algorithms on Matrix Manifolds*, Princeton University Press, 2008.

[12] A. Wächter et L. T. Biegler, *On the implementation of an interior-point filter line-search algorithm for large-scale nonlinear programming*, Mathematical Programming, vol. 106, no. 1, pp. 25-57, 2006.

[13] L. Bottou, *Large-scale machine learning with stochastic gradient descent*, Proceedings of COMPSTAT'2010, pp. 177-186, Physica-Verlag HD, 2010.

[14] L. Pronzato, *Minimax and maximin space-filling designs : some properties and methods for construction*, Journal de la Société Française de Statistique, vol. 158, no. 1, pp. 7-36, 2017.

[15] L. Ziyin, H. Li, et M. Ueda, *Noise balance and stationary distribution of stochastic gradient descent*, Physical Review E, vol. 111, no. 6, p. 65303, 2025.

[16] Auteurs divers, *Recent advances and challenges in the energy landscape of the Thomson problem*, arXiv preprint arXiv :2506.08398, 2025.

Annexe : Dynamique temporelle et spatiale de la Relaxation Combinatoire

L'observation directe de l'évolution spatiale au cours des itérations du SGD (via des enregistrements vidéo) couplée à l'analyse des histogrammes de suppression (comportement marginal) et des matrices de co-occurrence (comportement conjoint) permet de dégager des conclusions claires sur les distributions d'échantillonnage $q(X)$. Le but de ces heuristiques est de rejeter les mauvaises configurations pour faire baisser l'énergie, tout en conservant suffisamment de bruit pour sauter entre les bons minima.

1. Le repère de l'échantillonneur Uniforme (Entropie maximale)

L'échantillonneur uniforme explore tout l'espace des possibles sans aucun biais. Sa distribution marginale est parfaitement plate : chaque point a exactement la même probabilité d'être supprimé, indépendamment de sa position ou de l'énergie. Les légères variations observées ne sont que du bruit d'échantillonnage. Sur les matrices de co-occurrence, on observe un bruit statique homogène.

Visuellement, les points actifs apparaissent et disparaissent de manière totalement stochastique à la surface. La configuration géométrique n'a aucune influence : l'algorithme détruit constamment les bonnes structures que le SGD essaie de construire, empêchant toute convergence vers une énergie minimale. Il est inutile pour l'optimisation pure, mais sert de repère mathématique d'entropie maximale.

2. Le régime fluide de forte sur-paramétrisation ($n \gg m$)

Ce régime (ex : $m = 10, n = 50$ ou $m = 46, n = 100$) offre une grande liberté combinatoire, mais révèle des comportements très différents selon l'heuristique :

Dynamique de Boltzmann :

- *Marginale* : Les suppressions par point oscillent raisonnablement autour de la moyenne théorique uniforme. Aucun point n'est indispensable, et aucun n'est systématiquement rejeté. La distribution conserve une forte entropie.
- *Conjointe* : Les matrices de co-occurrence sont denses, prouvant que l'algorithme "mélange" bien les points. Presque toutes les paires possibles finissent par être supprimées ensemble.
- *Spatiale* : On observe un nuage de points actifs qui bouge et glisse constamment à la surface de la sphère, sautant de minimum local en minimum local et offrant une véritable diversité d'échantillonnage.

Dynamique de Belief Propagation (BP) :

- *Marginale* : Contrairement à Boltzmann, BP présente une distribution presque parfaitement uniforme, *à l'exception de quelques pics stricts* (points aberrants très souvent supprimés). BP calculant des probabilités marginales exactes, si certains points sont dans un amas dense, la croyance de devoir les supprimer tend vers 1. Le reste du nuage, lui, échange les points avec une parfaite uniformité.

— *Spatiale* : Les points actifs "clignotent" et rebondissent sur l'ensemble de la sphère plutôt que de glisser. Ce comportement global s'explique par le passage de messages : une modification mineure à un pôle peut instantanément changer la probabilité de sélection au pôle opposé. Ses sauts globaux cassant les corrélations locales, BP est largement supérieur à Boltzmann pour mélanger rapidement une configuration lorsqu'il a de la marge de manœuvre.

3. $n \approx m$

Lorsque le réservoir se resserre (ex : $m = 46, n = 50$, soit seulement 4 points à rejeter), le comportement devient presque déterministe (proche d'un Dirac sur le minimum énergétique) et l'entropie de trajectoire s'effondre.

Gel avec Boltzmann : L'immense majorité des points possède 0 suppression : l'algorithme a trouvé un sous-ensemble très stable et refuse de le casser car cela coûterait trop cher en énergie. La totalité des suppressions se concentre sur un petit groupe de 8 à 10 points spécifiques instables. La matrice de co-occurrence est presque entièrement noire, avec des interactions strictement limitées à ce petit groupe. Visuellement, la structure globale ne bouge quasiment pas ; seuls 4 points bougent et s'échangent occasionnellement avec des points de surface.

Gel avec Belief Propagation : Le phénomène est encore plus extrême. L'histogramme montre que 4 points sont systématiquement rejetés, tandis que les 46 autres ont un taux de rejet nul. L'algorithme fige instantanément une configuration quasi-optimale. La matrice de co-occurrence (totalement noire ponctuée de carrés jaunes distincts) révèle que les 4 points exclus ne s'excluent pas indépendamment : ils font l'objet d'échanges coordonnés très précis (des permutations locales pour tester des micro-variations). La structure forme un réseau stable gelé.

Conclusion sur le paramétrage

Si le but est l'optimisation pure (trouver la meilleure configuration), il faut utiliser $n \approx m$ (ou baisser la température via β ou τ). L'algorithme se comporte alors de manière gloutonne. À l'inverse, pour générer des distributions spatialement variées, les heuristiques ont impérativement besoin de $n \gg m$. Sans cette marge, les contraintes de répulsion géométrique de la sphère suppriment totalement l'aspect aléatoire de l'échantillonneur.

Annexe : Analyse comparative complète des échantillonneurs

L'observation de l'évolution spatiale au cours des itérations du SGD (via les enregistrements vidéo) couplée à l'analyse des histogrammes de suppression (comportement marginal) et des matrices de co-occurrence (comportement conjoint) permet de dégager des conclusions rigoureuses sur les distributions d'échantillonnage $q(\mathcal{X})$[cite : 169, 174]. Le but de ces heuristiques est de rejeter les configurations défavorables pour réduire l'énergie globale [cite : 204], tout en conservant un bruit stochastique suffisant pour naviguer dynamiquement entre les minima locaux[cite : 123, 191].

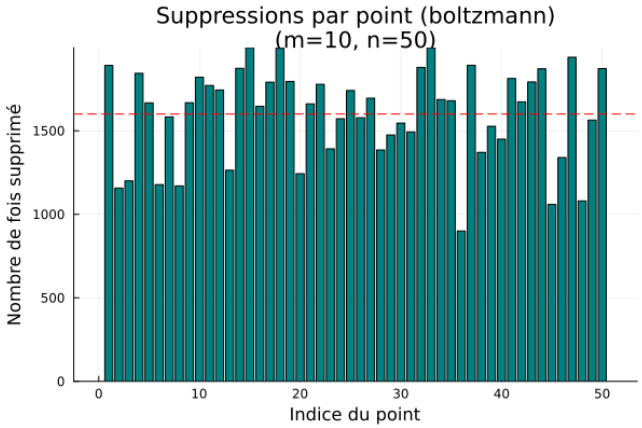
1. Régime fluide de forte sur-paramétrisation ($n = 50, m = 10$)

Ce premier régime se caractérise par une très grande fluidité structurelle et une plasticité maximale du réservoir[cite : 169, 279].

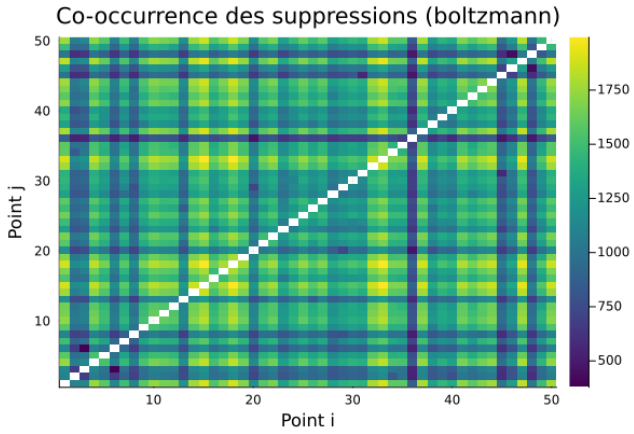
— **Boltzmann :** Les suppressions individuelles oscillent de manière homogène autour de la moyenne théorique uniforme[cite : 280, 281]. Aucun point n'est indispensable ni exclu de façon systématique, maintenant une distribution à forte entropie[cite : 281]. La matrice de co-occurrence associée est très dense, ce qui confirme un excellent brassage macroscopique : presque toutes les paires finissent par être éliminées conjointement au cours de la descente[cite : 282]. Visuellement, les points actifs forment un nuage fluide qui se reconfigure en glissant continuellement à la surface de la sphère.

— **Belief Propagation (BP) :** L'échantillonneur présente une distribution marginale globalement uniforme, à l'exception de quelques pics stricts correspondant à des zones de sur-densité locale où la croyance de devoir supprimer la particule tend vers 1[cite : 284]. Sur le plan spatial, les points actifs ne glissent pas mais "clignotent" et rebondissent à travers toute la sphère. Ces sauts globaux cassent efficacement les corrélations locales et assurent un mélange ultra-rapide du système[cite : 291].

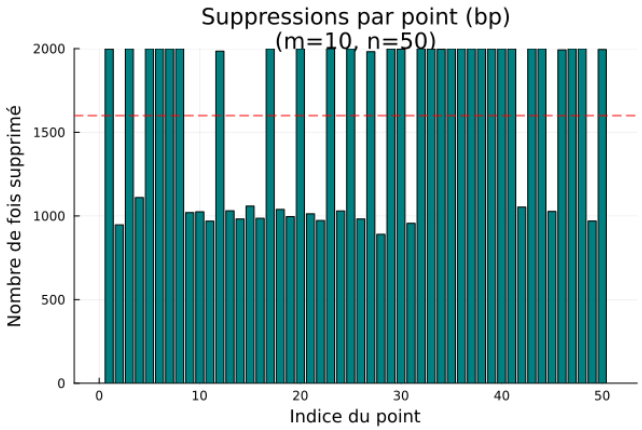
— **Uniforme :** La distribution est parfaitement plate (bruit d'échantillonnage pur) et la co-occurrence est un bruit statique homogène[cite : 292]. Ne prenant pas en compte la géométrie, l'échantillonneur uniforme détruit constamment les structures stables en cours de consolidation, empêchant toute minimisation efficace[cite : 293, 294].



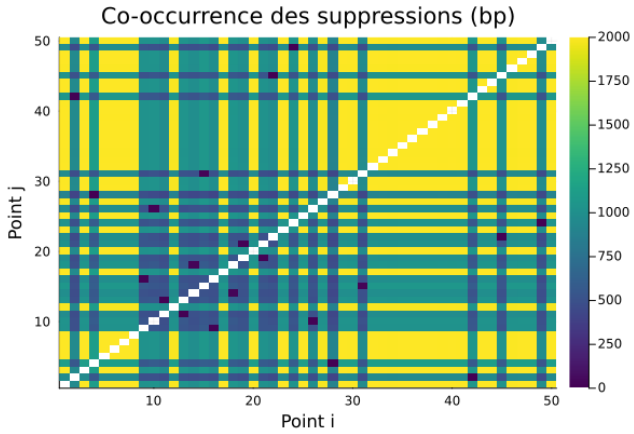
(a) Suppressions par point (Counts) — Boltzmann



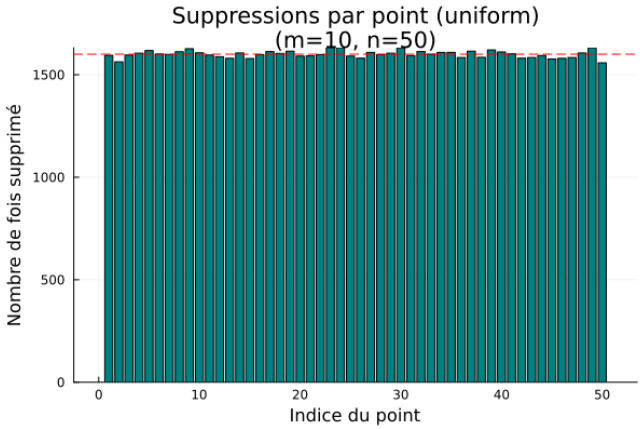
(b) Matrice de co-occurrence — Boltzmann



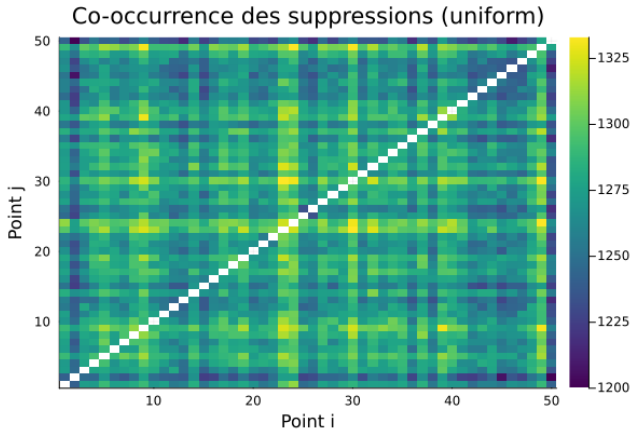
(c) Suppressions par point (Counts) — Belief Propagation



(d) Matrice de co-occurrence — Belief Propagation



(e) Suppressions par point (Counts) — Uniforme



(f) Matrice de co-occurrence — Uniforme

Figure 7 : Catalogue complet des dynamiques de sélection géométrique et combinatoire pour le couple $n = 50, m = 10$.

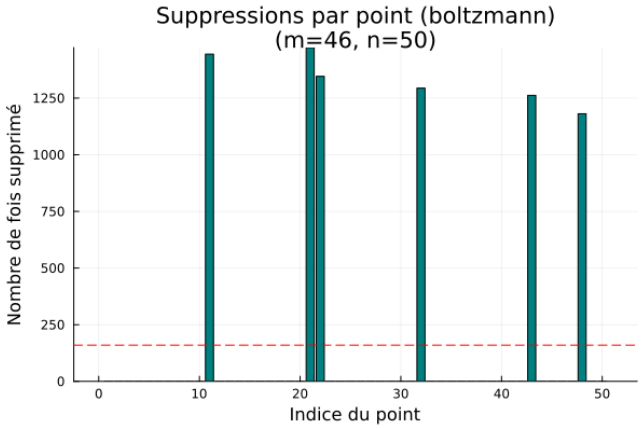
2. Régime $n \approx m$ ($n = 50, m = 46$)

Lorsque la taille du réservoir s'approche de la cardinalité cible, la pression combinatoire étouffe le comportement stochastique, provoquant un gel de la structure[cite : 285, 286].

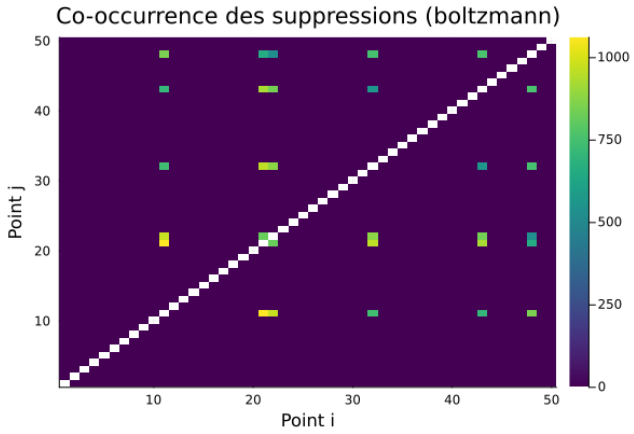
- **Boltzmann :** La distribution s'effondre vers un profil de Dirac[cite : 286]. L'immense majorité des atomes présente un taux de rejet nul car l'algorithme refuse de briser la symétrie du motif cristallin central trouvé[cite : 287, 289]. Les suppressions se concentrent exclusivement sur un noyau périphérique de 8 à 10 points instables[cite : 288]. La heatmap est presque entièrement noire et la vidéo montre une carapace rouge fixe où seuls les 4 points exclus dansent en surface[cite : 289].
- **Belief Propagation (BP) :** Le phénomène est poussé à son paroxysme[cite : 290]. Quatre points sont systématiquement rejetés tandis que les 46 autres restent intouchables[cite : 290]. La matrice de co-occurrence fait apparaître des blocs géométriques discrets et contrastés (carrés jaunes), révélant que les exclusions ne sont pas indépendantes mais correspondent à des micro-échanges coordonnés (permutations locales)[cite : 291].
- **Uniforme :** Indifférent au gel, il maintient sa distribution plate et son bruit statique[cite : 292]. Il continue de perturber la structure sans discernement, confirmant son rôle exclusif de repère théorique de l'entropie maximale.

3. Régime intermédiaire à grand réservoir ($n = 100, m = 46$)

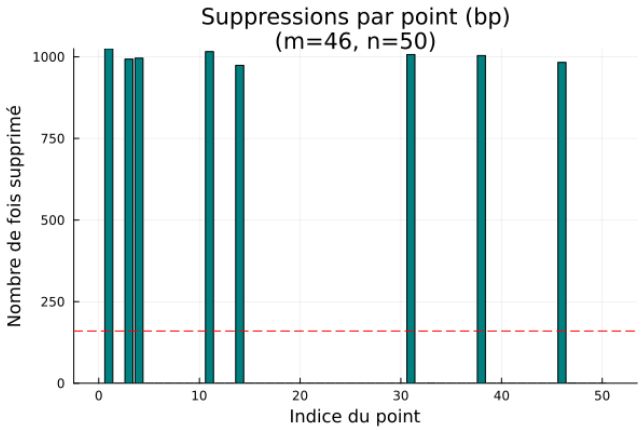
L'augmentation de la taille du pool à $n = 100$ pour la cible complexe $m = 46$ permet de restaurer la fluidité stochastique par rapport au cas critique précédent[cite : 251, 285]. En élargissant l'espace des phases, on évite le gel précoce rencontré à $n = 50$[cite : 251, 286]. Les comportements de Boltzmann et de BP retrouvent des profils similaires à ceux du cas fluide (50/10), mais appliqués à une topologie cristalline de grande taille, validant le fait que la surparamétrisation du réservoir est le levier principal pour contrôler l'entropie de l'échantillonneur[cite : 169, 272].



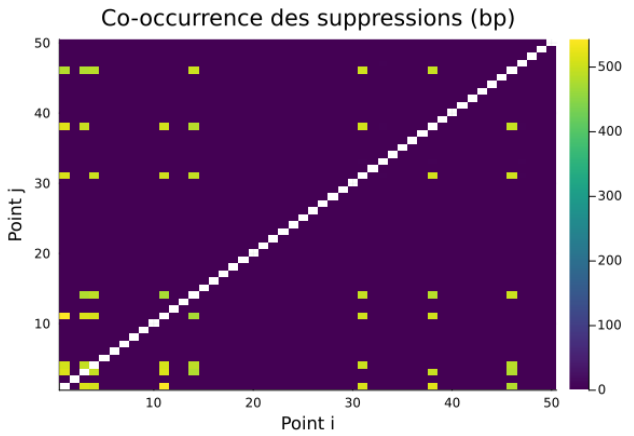
(a) Suppressions par point (Counts) — Boltzmann



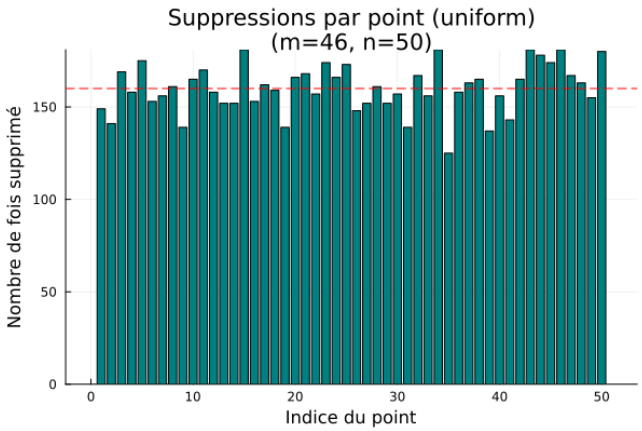
(b) Matrice de co-occurrence — Boltzmann



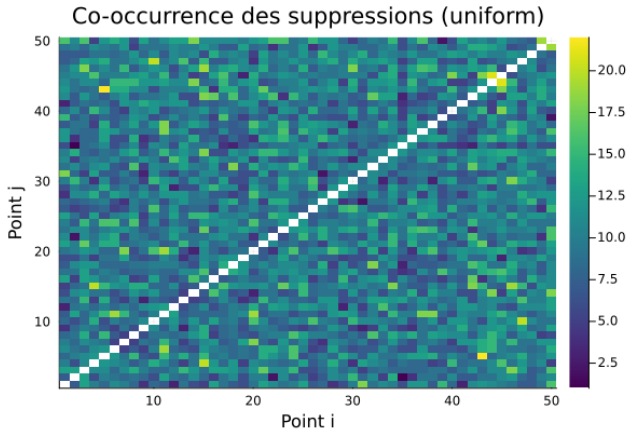
(c) Suppressions par point (Counts) — Belief Propagation



(d) Matrice de co-occurrence — Belief Propagation

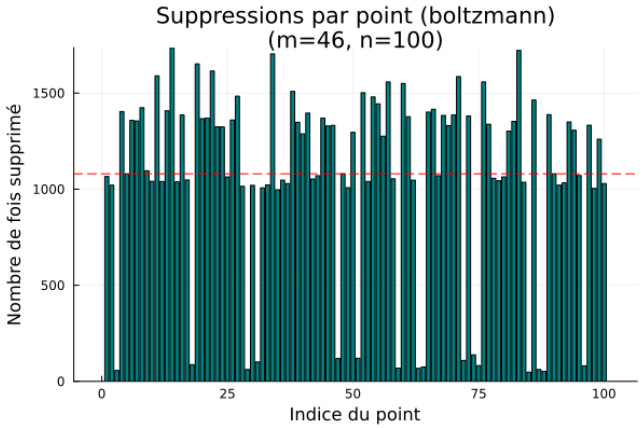


(e) Suppressions par point (Counts) — Uniforme

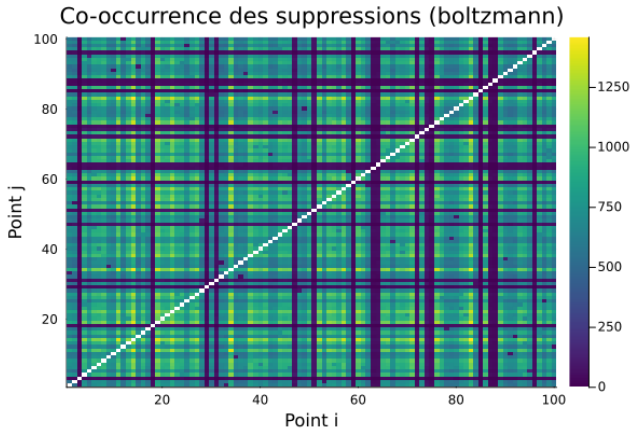


(f) Matrice de co-occurrence — Uniforme

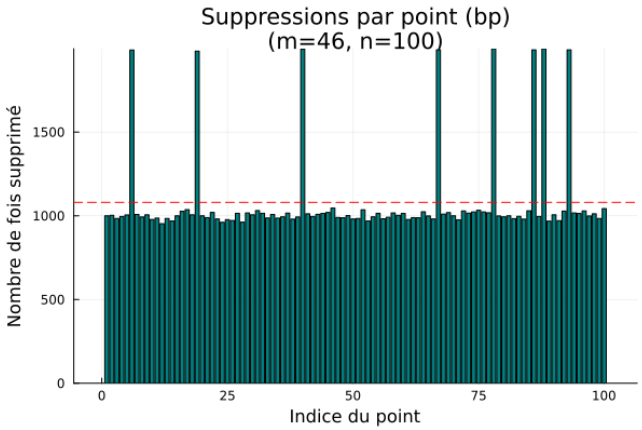
Figure 8 : Catalogue complet des dynamiques de sélection géométrique et combinatoire pour le couple $n = 50, m = 46$.



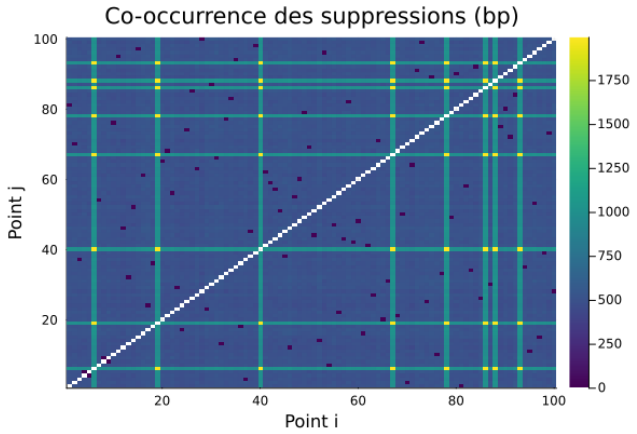
(a) Suppressions par point (Counts) — Boltzmann



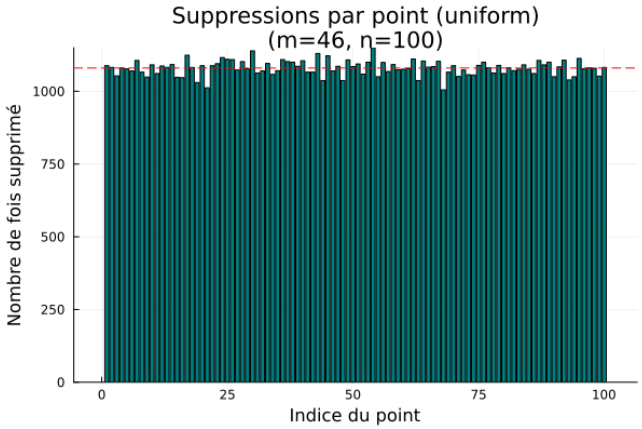
(b) Matrice de co-occurrence — Boltzmann



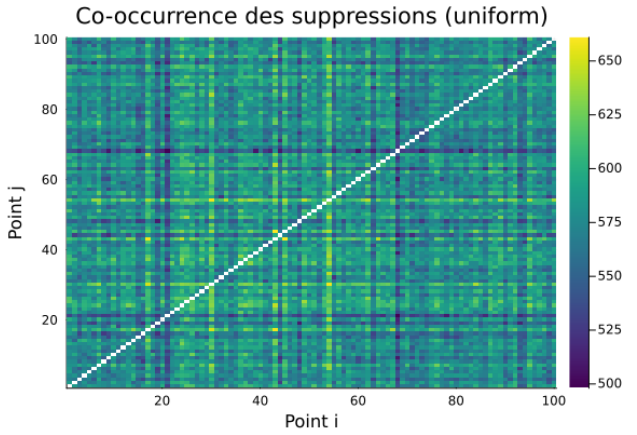
(c) Suppressions par point (Counts) — Belief Propagation



(d) Matrice de co-occurrence — Belief Propagation



(e) Suppressions par point (Counts) — Uniforme



(f) Matrice de co-occurrence — Uniforme

Figure 9 : Catalogue complet des dynamiques de sélection géométrique et combinatoire pour le couple $n = 100, m = 46$.